

INFORME EJECUTIVO: ANÁLISIS MULTIDIMENSIONAL DE LA BÚSQUEDA LABORAL ESTUDIANTIL

Autores:

- Juan Diego Grajales Castillo | Julian David Celis Giraldo
- David Santiago Aldana Gonzalez | Sara Nicolle Martinez Moreno

1. Resumen Ejecutivo

Este informe presenta un análisis riguroso y predictivo del proceso de inserción laboral estudiantil, utilizando técnicas avanzadas de Minería de Datos sobre una base de 100,000 registros históricos. El problema se aborda desde tres perspectivas metodológicas integradas:

1. Clasificación Supervisada: Identificación del perfil de estudiantes propensos a recibir ofertas de empleo.
2. Regresión Supervisada: Estimación de la compensación salarial anual obtenida por los estudiantes exitosos.
3. Agrupamiento No Supervisado (Clustering): Descubrimiento de perfiles y comportamientos de búsqueda para guiar tutorías.


El objetivo final es proveer información estratégica y accionable a las directivas universitarias y centros de desarrollo profesional para orientar sus currículos y alianzas estratégicas corporativas.

2. Auditoría de Calidad y Procesamiento de Datos

La auditoría del dataset reveló un total de 100,000 registros únicos libres de duplicados exactos. Se identificaron valores faltantes estructurales correspondientes al 65.77% de la muestra en las variables de outcome (salario, días de espera para la oferta, tamaño de la empresa), los cuales corresponden directamente a estudiantes que no recibieron una oferta (clase negativa). Este comportamiento es estructural, por lo que no se imputaron, sino que se aislaron de manera natural al segmentar las bases para los modelos de regresión y clasificación.

Se mantuvo el total de registros en la variable GPA, conservando incluso calificaciones atípicas inferiores a 2.5 para evitar sesgar los algoritmos predictivos hacia estudiantes únicamente de alto rendimiento académico.

3. Hallazgos del Análisis Exploratorio de Datos (EDA)



A partir de los gráficos expuestos se extraen conclusiones críticas:

- La tasa de conversión (éxito de oferta) promedio es superior en la plataforma Handshake en comparación con LinkedIn o Indeed, sugiriendo que los canales institucionales especializados proveen un mayor éxito de conversión laboral, a pesar de que Indeed y LinkedIn gestionan un volumen bruto de postulaciones muy superior.
- Existe una fortísima correlación (+0.67) entre llegar a las segundas rondas de entrevistas (Second_Round_Interviews) y recibir la oferta. Por el contrario, el número de aplicaciones enviadas presenta una correlación lineal casi nula. Esto valida que saturar el mercado de postulaciones no es eficaz si no se superan las fases medias del proceso.

4. Evaluación de Modelos de Clasificación

Resultados de desempeño al predecir la probabilidad de recepción de oferta laboral (Offer_Received):

Modelo	Exactitud	Precisión	Recall	F1-Score	ROC-AUC
Logistic Regression	0.7713	0.6054	0.9533	0.7405	0.8940
KNN	0.8380	0.6973	0.9312	0.7974	0.9346
Decision Tree	0.8894	0.7593	0.9911	0.8598	0.9672
Random Forest	1.0000	1.0000	1.0000	1.0000	1.0000
Naive Bayes	0.7743	0.6127	0.9258	0.7374	0.8803
SVM	0.8900	0.7769	0.9519	0.8556	0.9590

Nota de Análisis: Los modelos SVM RBF y Decision Tree presentan el mejor desempeño predictivo robusto con precisiones cercanas al 89% y recall sobresaliente superior al 95%. Aunque Random Forest presenta métricas perfectas (1.0), este fenómeno denota un sobreajuste o filtración de variables de target, por lo que para producción se prefieren SVM y Decision Tree.

5. Evaluación de Modelos de Regresión (Salario Ofertado)

Resultados en la predicción del salario anual ofertado (Offer_Salary) en la subpoblación con oferta aprobada:

Modelo Regresor	MAE (\$USD)	MSE	RMSE (\$USD)	R ² (Coef. Det.)
Lasso	\$6339.79	6.31e+07	\$7941.93	0.7085
Ridge	\$6341.34	6.31e+07	\$7944.57	0.7083
Linear Regression	\$6341.34	6.31e+07	\$7944.59	0.7083
Decision Tree Regressor	\$6510.07	6.65e+07	\$8152.49	0.6928
Random Forest Regressor	\$6421.54	6.45e+07	\$8031.73	0.7018

Nota de Análisis: Los modelos lineales regularizados (Lasso y Ridge) logran una capacidad explicativa superior, consiguiendo un R² de 0.7085. Esto demuestra que la relación de los predictores con la escala salarial final es eminentemente lineal, registrando un margen de error absoluto medio (MAE) de aproximadamente \$6,340 USD anuales.

6. Modelos de Clustering (Segmentación de Estudiantes)

Algoritmo	Coeficiente Silhouette	Índice Dunn
KMeans	0.0608	0.1683
Hierarchical	0.1389	0.3602
DBSCAN	0.1225	0.3058

Nota de Análisis: Aunque el coeficiente Silhouette es bajo (denotando perfiles estudiantiles con límites superpuestos), el Clustering Jerárquico muestra la mayor definición estructural. El agrupamiento segmenta fuertemente a los estudiantes según su plataforma de búsqueda primaria y el prestigio de su universidad de origen.

7. Conclusiones y Recomendaciones Corporativas

- Foco en el Entrenamiento de Entrevistas: Avanzar en segundas rondas es el mayor catalizador de la inserción laboral. Se recomienda a las facultades rediseñar sus mentorías y simulacros enfocándolos en las etapas intermedias de evaluación técnica y entrevistas de segunda ronda.
- Fortalecimiento de Canales Institucionales: Handshake demuestra mayor efectividad que Indeed o LinkedIn. Es crucial que la institución promueva de forma activa el registro y postulación a través de convenios directos corporativos.
- Segmentación de Mentorías: Utilizar los perfiles descubiertos por clustering para personalizar las tutorías según el nivel académico y las plataformas de postulación utilizadas.