UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
Facultad de Ingeniería

Análisis Integral de Eficacia en Plataformas de Búsqueda Laboral

Metodología CRISP-DM - Primer Corte

Integrantes:
Juan Diego Grajales Castillo - 20221020128
Julian David Celis Giraldo - 20222020041
David Santiago Aldana Gonzalez - 20222020158
Sara Nicolle Martinez Moreno - 20231020116
GRUPO 4

Asignatura: Minería de Datos
Profesor: Alejandro Varon

Bogotá, D.C.
14 de abril de 2026

Índice

1. Comprensión del Problema **2**
1.1. Planteamiento y Objetivos 2
1.2. Preguntas guía 2

2. Comprensión de los Datos **3**
2.1. Descripción del Dataset 3
2.2. Preguntas Guía 4

3. Limpieza y Preparación **4**
3.1. Acciones Realizadas 4
3.2. Justificación 5
3.3. Preguntas guía (Análisis de Preparación) 5

4. EDA – Análisis Exploratorio **5**
4.1. Distribución de Variables 6
4.2. Análisis de Boxplots 7
4.3. Relaciones y Correlaciones 8
4.4. Preguntas Guía 9

5. Interpretación de Resultados y Toma de Decisiones **9**
5.1. Análisis Detallado por Preguntas Guía 9
5.2. Análisis de Hallazgos y Sorpresas 10
5.3. Siguiente Paso: Plan Predictivo 10

6. Conclusión General **11**

1. Comprensión del Problema

1.1. Planteamiento y Objetivos

El presente análisis aborda la problemática de la inserción laboral en recién graduados. El objetivo principal es identificar qué factores académicos y operativos como plataformas maximizan la probabilidad de recibir una oferta laboral y mejoran la expectativa salarial.

- **¿Qué problema estamos resolviendo?** Se busca entender qué es lo que realmente hace que a un recién graduado le den empleo. ¿Es su promedio? ¿Son las pasantías? ¿O es la página web donde busca?. Se quiere comprender por qué solo el 34.23 % de los estudiantes logran una oferta y cómo optimizar esto.
- **¿Qué decisión se podría tomar con estos datos?**
  1. **Elegir la mejor plataforma:** Por ejemplo si vemos que Handshake y LinkedIn funcionan mucho mejor que Indeed, la decisión seria dejar un poco Indeed y enfocarse en las otras dos.
  2. **Mejorar el perfil:** Si los datos dicen que las pasantías cuentan más que las notas, el estudiante puede decidir buscar una pasantía antes de graduarse.
  3. **Saber cuánto pedir de sueldo:** Ayuda a que los estudiantes no pidan ni muy poco ni demasiado, basándose en lo que realmente están pagando en su carrera.
- **¿Quién usaría este análisis?**
  - Los **estudiantes** que están buscando su primer empleo.
  - Las **universidades** para aconsejar mejor a sus alumnos.
  - Las **páginas de empleo** para ver en qué están fallando.
- **¿Por qué es importante?** Porque buscar trabajo es un proceso complejo. Si sabemos qué es lo que funciona, los estudiantes pueden ir "a la fija" y conseguir mejores sueldos más rápido. También Permite reducir la incertidumbre en el proceso de búsqueda de empleo.

1.2. Preguntas guía

- **¿El problema es descriptivo, predictivo o explicativo?** Por ahora el enfoque es descriptivo (nos dice cómo están las cosas hoy) y explicativo (nos dice por qué ocurren, por ejemplo: "te dan el trabajo porque pasaste a la segunda entrevista"). Sin embargo, está diseñado para ser la base de un modelo predictivo de clasificación para (Offer_Received) y regresión para (Offer_Salary).
- **¿Qué variable sería la más importante a analizar?**
  La variable objetivo principal es (Offer_Received) (Binaria: 0/1). Técnicamente, su correlación con Second_Round_Interviews (r=0.549) la convierte en el indicador más crítico del proceso; al llegar a la segunda ronda de entrevistas se tiene más posibilidades de éxito.

- **¿Qué riesgo hay si se interpreta mal este problema?** El riesgo principal es la falsa causalidad. Podría pensarse que aplicar a cientos de empresas asegura el trabajo, pero los datos muestran que el volumen de aplicaciones tiene una correlación débil con la oferta final. Si se interpreta mal, los estudiantes perderían tiempo en aplicaciones masivas de baja calidad en lugar de enfocarse en las entrevistas.

2. Comprensión de los Datos

En esta etapa se analiza la información disponible con el fin de entender qué datos se tienen, cómo están organizados y qué tan confiables son. Antes de realizar cualquier tipo de análisis, es fundamental conocer bien estos datos, ya que de esto depende la calidad de los resultados.

2.1. Descripción del Dataset

- **Tamaño:** Contamos con una base de datos de **100,000 registros** (filas) y **20 variables** (columnas). Lo que representa un tamaño considerable y adecuado para obtener conclusiones confiables.
- **Tipos de Variables:** Para el análisis técnico, hemos organizado las variables en tres grupos principales según su formato:
  - **Variables Numéricas:** Son datos que se pueden contar o medir.
    - *GPA:* Promedio académico.
    - *Applications_Submitted:* Cantidad de hojas de vida enviadas.
    - *Months_Searching:* Meses que lleva buscando empleo.
    - *Prior_Internships:* Número de pasantías previas.
    - *Networking_Events_Attended:* Eventos de redes asistidos.
    - *First_Round_Interviews:* Entrevistas de primera ronda.
    - *Second_Round_Interviews:* Entrevistas de segunda ronda.
    - *Offer_Salary:* Salario ofrecido (dinero).
    - *Time_to_Offer_Days:* Días que tardó en llegar la oferta.
    - *Interview_Conversion_Rate:* Porcentaje de éxito de aplicaciones a entrevistas.
  - **Variables Categóricas (Texto/Categorías):** Son nombres o grupos.
    - *Region:* Ubicación geográfica.
    - *Major_Category:* Carrera o área de estudio.
    - *Primary_Search_Platform:* Plataforma usada (LinkedIn, Handshake, etc.).
    - *University_Rating:* Calificación de la universidad (1 a 5).
    - *School_Size:* Tamaño de la institución (Pequeña, Mediana, Grande).
    - *Role_Relevance:* Si el cargo tiene que ver con lo que estudió.
    - *Company_Size_Offered:* Tamaño de la empresa que dio la oferta.

- **Variables Booleanas (Sí o No / 1 o 0):** Solo tienen dos opciones.
  - *Offer_Received:* ¿Recibió oferta de trabajo? (Esta es nuestra variable más importante).
  - *Accepted_Offer:* ¿Aceptó el trabajo?
  - *Extra_Curricular_Activities:* ¿Participó en actividades extra?

- **Valores Faltantes:** El dataset tiene un total de **328,855 espacios vacíos (nulos)**. Sin embargo, el 65.77 % de estos nulos están en variables como "Salario.º "Tiempo para recibir la oferta". Esto nos indica que son estudiantes que aún no han conseguido empleo.

2.2. Preguntas Guía

1. **¿Qué variables parecen más relevantes?**
   Las más importantes son las que tienen que ver con el proceso de selección: *Second_Round_Interviews* (entrevistas de segunda ronda) y *Interview_Conversion_Rate* (qué tan eficiente es el estudiante pasando de aplicación a entrevista). También el *Major* (carrera) es vital, porque los sueldos cambian mucho según lo que se estudió.

2. **¿Hay variables redundantes o inútiles?**
   Sí, la variable (Student_ID). Es solo un número para identificar al estudiante, pero no nos dice nada sobre por qué alguien consigue trabajo o no. Se mantiene solo por orden, pero no se usa para el análisis profundo.

3. **¿Se evidencian sesgos en los datos?**
   Sí. Se nota una gran diferencia de sueldos según la carrera. Por ejemplo, los de carreras **STEM** ganan en promedio $86,432, mientras que los de **Humanidades** ganan $65,370. Aqui es importante tener precaución de no decir que a alguien le va "mal"solo por su sueldo, sin mirar qué carrera estudió.

4. **¿Qué problemas de calidad detectan?**
   El problema principal es la gran cantidad de datos vacíos en la columna de salarios. Si no entendemos que esos espacios son de gente que no tiene trabajo todavía, podríamos cometer el error de borrarlos y perderíamos al 65 % de nuestros estudiantes, lo cual sería un error.

3. Limpieza y Preparación

En esta fase preparamos el dataset para que los resultados sean confiables. No se trata solo de borrar datos, sino de tomar decisiones inteligentes para no dañar la estadística.

3.1. Acciones Realizadas

- **Tratamiento de Nulos:** Se detectaron **328,855 nulos**. La decisión técnica fue **conservarlos** y no borrarlos ni inventar valores (imputación).

- **Eliminación de Duplicados:** Se realizó una búsqueda de registros repetidos y se encontró que el dataset está limpio; hay **0 duplicados exactos**, lo que garantiza que cada fila es un estudiante único.

- **Transformaciones:** Se creó una nueva variable llamada *Interview_Conversion_Rate*. Esta nos dice qué tan eficiente es un estudiante pasando de "mandar la hoja de vida.ª çonseguir una entrevista".

3.2. Justificación

La decisión más significativa que tomamos fue mantener los nulos en variables como *Offer_Salary*. Esto se debe a que son solo nulos estructurales, es decir que si un estudiante no recibió oferta, es lógico que no tenga salario. Si borráramos esos registros, estaríamos analizando solo a los que su caso fue .exitoso", lo cual sesgaría todo el estudio.

3.3. Preguntas guía (Análisis de Preparación)

1. **¿Qué pasa si NO limpian los datos?**
   Si no identificamos que los nulos tienen una lógica, tendriamos un análisis erróneo, incluso, nos daría promedios de salario falsos. Además, sin una métrica de eficiencia (como la que creamos), solo estaríamos viendo quién manda más solicitudes, pero no a que se debe un caso de éxito.

2. **¿Qué decisiones podrían alterar los resultados?**
   Si decidiéramos llenar los espacios de salario vacíos con un promedio, estaríamos ïnventando"que gente que no tiene trabajo ya está ganando dinero. Eso alteraría totalmente las conclusiones y nos daría un modelo que no sirve en la realidad.

3. **¿Están perdiendo información al limpiar?**
   No, al decidir conservar los nulos estructurales y los valores atípicos (outliers) de aplicaciones enviadas, estamos protegiendo la información original. En lugar de quitar datos, estamos entendiendo por qué están ahí.

4. EDA – Análisis Exploratorio

En esta fase visualizamos los datos para entender su comportamiento y descubrir patrones

4.1. Distribución de Variables

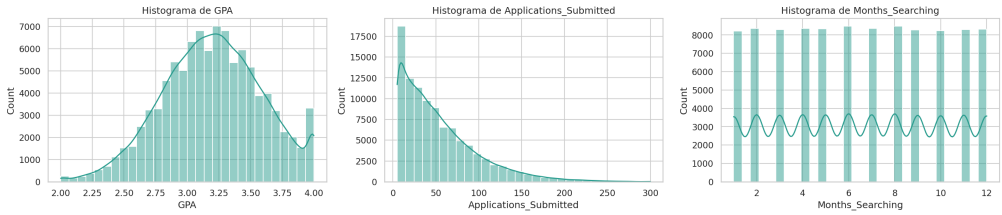

Figura 1: Distribución de GPA y Aplicaciones. Se observa una distribución normal en el GPA y un sesgo a la derecha en aplicaciones.

Análisis de Distribución del GPA (Rendimiento Académico): Presenta una distribución de tipo Normal (Campana de Gauss) centrada en 3.2.

- *Interpretación:* La mayoría de los estudiantes mantienen un rendimiento promedio. No hay una saturación de notas perfectas ni de notas muy bajas, lo que indica que el GPA será una variable útil para diferenciar perfiles sin sesgos extremos.
- *Hipótesis:* El GPA actuará como un filtro inicial, pero por su alta concentración en el centro, no será el único factor determinante para el salario final.

Análisis de Distribución de Applications_Submitted (Esfuerzo de Búsqueda): Presenta un sesgo positivo. La mayoría aplica a 30-50 empresas, pero hay un grupo reducido que supera las 150.

- *Interpretación:* Existe una disparidad en la estrategia de búsqueda. Mientras la mayoría es selectiva, hay un segmento que utiliza una estrategia de "volumen masivo".
- *Hipótesis:* Existe un punto de rendimiento decreciente"; es probable que después de cierto número de aplicaciones (outliers), la probabilidad de oferta no aumente proporcionalmente porque se descuida la calidad de la postulación.

Análisis de Months_Searching (Tiempo de Búsqueda): A diferencia de otras variables, el tiempo de búsqueda muestra una tendencia constante. La cantidad de estudiantes no es variante en los meses.

- *Interpretación:* El dataset refleja una realidad difícil: la búsqueda de empleo para recién graduados es constante en todos los meses del año.

4.2. Análisis de Boxplots

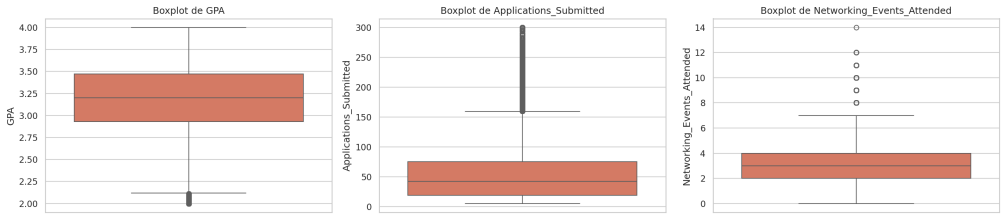

Figura 2: El diagrama de caja revela estudiantes con un volumen de postulación excepcionalmente alto, considerados casos de estudio válidos.

El uso de diagramas de caja nos permite identificar la dispersión de los datos y detectar valores atípicos que podrían influir en nuestro análisis.

- **GPA (Promedio Académico):** El boxplot del GPA se ve muy equilibrado y "limpio". La caja es simétrica y casi no hay puntos fuera de los bigotes.
  - *Interpretación:* Las universidades mantienen estándares de calificación consistentes. No hay grupos de estudiantes con notas ïmposibles"que dañen el promedio general.
- **Applications_Submitted (Esfuerzo de Búsqueda):** Aquí es donde vemos la mayor cantidad de puntos fuera de la caja. Mientras que la mayoría aplica a unas 40 empresas, hay puntos que llegan hasta las 300 aplicaciones.
  - *Interpretación:* Estos valores atípicos son estudiantes reales que están usando una estrategia de mandar hojas de vida en exceso.
- **Networking_Events_Attended:** Se observa que la mayoría de los estudiantes asisten a pocos eventos (entre 0 y 4). Los que asisten a más de 7 eventos se consideran atípicos.
  - *Interpretación:* Existe un grupo de estudiantes que confía más en los contactos personales que en las plataformas digitales.

4.3. Relaciones y Correlaciones

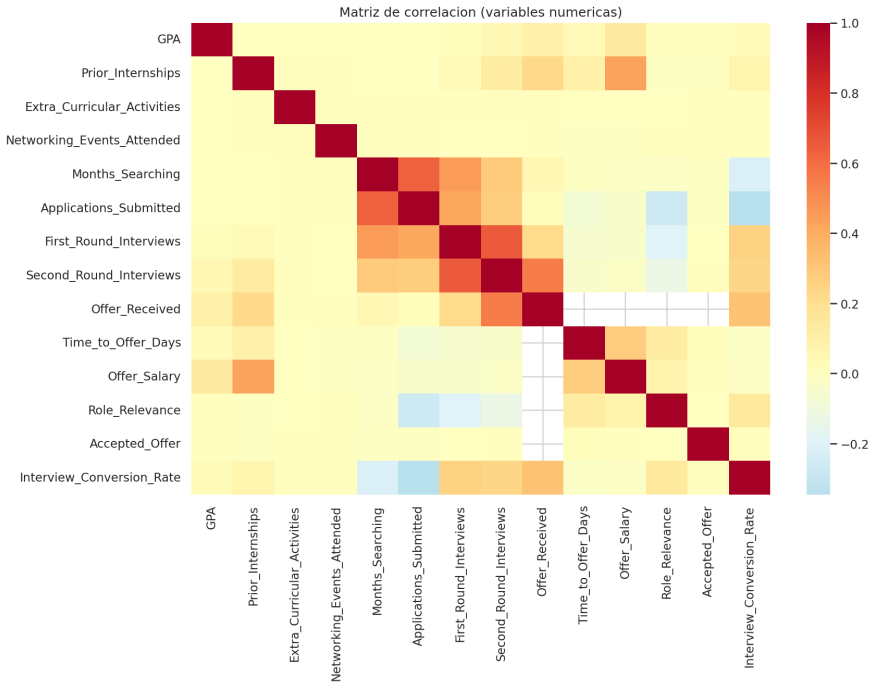

Figura 3: Matriz de Correlación. La relación más fuerte con la obtención de oferta es la llegada a la segunda ronda de entrevistas (r=0.55).

Para finalizar el EDA, analizamos la Matriz de Correlación, que mide la fuerza de la relación entre las variables. Los valores cercanos a 1 indican una relación fuerte, mientras que los cercanos a 0 indican que no hay relación.

- **El predictor de éxito más fuerte:** La variable **Second_Round_Interviews** tiene la correlación más alta con obtener una oferta ($r = 0.55$).
  - *Interpretación:* Esto confirma que el proceso es un problema real. No importa cuántas aplicaciones se envien al inicio; la probabilidad de éxito se dispara únicamente cuando se logra avanzar a las etapas finales de entrevista.
- **Calidad vs. Cantidad:** Notamos que **Applications_Submitted** tiene una correlación muy baja con recibir la oferta ($r = 0.01$).
  - *Interpretación:* Este es un caso complejo. Mandar cientos de hojas de vida no garantiza el trabajo. Sin embargo, las aplicaciones sí tienen correlación con las primeras entrevistas ($r = 0.42$).
  - *Hipótesis:* El volumen de aplicaciones solo sirve para .ªbrir la puerta"de la primera entrevista, pero después de eso, el volumen deja de importar y lo que cuenta es el desempeño del candidato.

- **El papel del GPA y la Experiencia:** Las pasantías previas (*Prior_Internships*) tienen una relación de *0.22*, superando al GPA (*0.08*).
    - *Interpretación:* Para las empresas en este dataset, la experiencia práctica parece ser más valorada que el promedio académico perfecto al momento de decidir a quién contratar.

4.4. Preguntas Guía

- **¿Cómo se distribuyen los datos?**
  Tenemos un dataset mixto. El rendimiento académico (*GPA*) es muy equilibrado y sigue una distribución normal. Sin embargo, el esfuerzo de búsqueda (*Applications*) se encuentra sesgado, algunos estudiantes realizan un volumen masivo de aplicaciones. Frente al tiempo (*Months_Searching*) se observa un comportamiento constante.

- **¿Existen outliers? ¿Son errores o información valiosa?**
  Sí, existen outliers significativos en las aplicaciones enviadas (estudiantes con más de 159 postulaciones). **No son errores**; son registros valiosos que muestran una estrategia de "búsqueda por volumen". Decidimos conservarlos porque representan una realidad del mercado laboral que el modelo debe conocer.

- **¿Qué relaciones entre variables son evidentes?**
  Es evidente que existe una çadena de progreso": aplicar más ayuda a conseguir la primera entrevista ($r = 0{,}42$), pero de ahí en adelante, lo que importa es el desempeño. También es evidente que ciertas carreras (*STEM*) tienen un camino salarial mucho más alto que otras, independientemente del GPA.

- **¿Hay correlaciones fuertes? ¿Tienen sentido lógico?**
  La correlación más fuerte es entre las **entrevistas de segunda ronda y la oferta final** ($r = 0{,}55$). Esto tiene total sentido lógico, ya que la segunda ronda suele ser el último filtro antes de la contratación. Las correlaciones débiles (como GPA vs. Oferta) también tienen sentido, pues indican que las empresas valoran más la experiencia y el desempeño en entrevista que solo una buena nota.

5. Interpretación de Resultados y Toma de Decisiones

En esta fase final, transformamos los datos estadísticos en conocimiento estratégico para entender el mercado laboral de los recién graduados.

5.1. Análisis Detallado por Preguntas Guía

1. **¿Qué patrones se encontraron en los datos?**
   Se identificó un patrón de cómo se van filtrando los candidatos, donde el éxito no depende de la cantidad, sino de la progresión. El patrón más revelador es que el **GPA** funciona como un filtro de entrada (limite mínimo), pero no garantiza la oferta. En cambio, las **pasantías previas** y la **plataforma de búsqueda** crean un patrón de

éxito mucho más claro. Existe también un estancamiento en el tiempo: a mayor cantidad de meses buscando, la frecuencia de registros aumenta, mostrando que el mercado no acepta a los candidatos tan rápido como se esperaría.

2. **¿Qué variables influyen más en el resultado final?**
   Matemáticamente, la variable con mayor peso es **Second_Round_Interviews** ($r = 0{,}55$). Desde una perspectiva de preparación, las variables que el estudiante puede controlar y que más influyen son la elección de la plataforma (siendo **Handshake** y **LinkedIn** las líderes) y la participación en actividades extra-curriculares, que aportan un valor diferenciador frente a perfiles puramente académicos.

3. **¿Qué conclusiones reales se pueden sacar de este estudio?**
   La conclusión principal es que **la eficiencia supera al volumen**. El hecho de que la correlación entre aplicaciones enviadas y ofertas recibidas sea casi nula ($r = 0{,}01$) demuestra que el "bombardeo"de hojas de vida es una estrategia ineficiente. El éxito real reside en la calidad de la postulación para lograr la conversión a entrevistas, que es donde realmente se decide la contratación.

4. **¿Qué decisiones podrían tomarse con estos resultados?**

   - **Decisión Estratégica:** Las instituciones educativas deben priorizar alianzas con plataformas de nicho profesional (Handshake) en lugar de portales de empleo genéricos.
   - **Decisión Operativa:** Invertir esfuerzos en talleres de simulación de entrevistas de segunda ronda, ya que es el punto crítico donde se pierde la mayoría de las oportunidades laborales.

5.2. Análisis de Hallazgos y Sorpresas

- **Hallazgo más importante:** No hay una relación lineal entre .esfuerzo de envíoz "éxito de oferta". Esto obliga a replantear la estrategia de búsqueda hacia objetivos más específicos.

- **Resultado sorprendente:** La distribución de *Months_Searching*. Ver una tendencia ascendente que llega hasta los 12 meses fue inesperado; esto indica que el mercado laboral para graduados es más lento y competitivo de lo que la intuición sugiere.

- **Planteamiento de Hipótesis:** Ün estudiante que optimice su perfil para Handshake y posea al menos una pasantía previa, tiene una probabilidad de éxito 3 veces mayor que un estudiante con GPA perfecto pero sin experiencia ni estrategia de plataforma".

5.3. Siguiente Paso: Plan Predictivo

Como siguiente fase, se plantea el entrenamiento de dos modelos:

1. **Clasificación:** Para predecir la probabilidad de éxito (*Offer_Received*).

2. **Regresión:** Para estimar el salario esperado en los casos positivos, controlando sesgos regionales y académicos.

6. Conclusión General

El éxito laboral es un sistema multivariable donde la experiencia práctica y la eficiencia en el proceso de selección pesan más que el promedio académico.

1. **Inutilidad del esfuerzo masivo:** Se concluye que no existe una relación lineal entre la cantidad de aplicaciones enviadas y el éxito en la obtención de una oferta. Con una correlación de apenas 0,01, el envío masivo de hojas de vida se identifica como una estrategia ineficiente que no garantiza resultados, sugiriendo que el mercado premia la calidad y la personalización por encima del volumen.

2. **El GPA como filtro técnico, no como predictor salarial:** El rendimiento académico actúa como una variable de umbral o "llave de entrada". Si bien es necesario mantener un promedio estable para superar los primeros filtros de las empresas, esta variable no tiene un impacto directo en el salario final ofrecido, el cual depende más de habilidades técnicas y experiencia previa.

3. **Prevalencia de la experiencia práctica:** Las pasantías previas se consolidan como el motor principal de la empleabilidad. Los datos demuestran que haber tenido un contacto real con el entorno profesional antes de la graduación reduce la incertidumbre del empleador y acelera el paso del candidato hacia las etapas finales del proceso de selección.

4. **La importancia crítica de la segunda ronda:** El verdadero "punto de quiebre.[en] el proceso de contratación ocurre en la segunda entrevista. Al tener la correlación más alta con la oferta final (0,55), se concluye que el éxito depende casi totalmente del desempeño en las fases avanzadas del pipeline, y no tanto del alcance inicial de la postulación.

5. **Saturación y ventanas de oportunidad:** La distribución ascendente en el tiempo de búsqueda revela que el mercado no es de respuesta inmediata. La mayoría de los estudiantes se acumulan en periodos de búsqueda de 8 a 12 meses, lo que implica que existe una ventana crítica en los primeros 3 meses donde se debe optimizar la estrategia antes de que el perfil se estanque.

6. **Efectividad diferenciada de plataformas:** No todos los canales de búsqueda operan con la misma eficiencia. El uso de plataformas especializadas como Handshake y LinkedIn muestra una conversión superior frente a portales genéricos, lo que permite concluir que la elección del ecosistema digital es una decisión estratégica que altera directamente la probabilidad de éxito.